Лабораторна робота
з дисципліни “Інтелектуальний аналіз даних”

ВИКОРИСТАННЯ ЗАСОБІВ ВІЗУАЛІЗАЦІЇ ПАКЕТУ MINESET ДЛЯ ПРОВЕДЕННЯ „РОЗВІДУВАЛЬНОГО” АНАЛІЗУ БАГАТОВИМІРНИХ ДАНИХ

Мета лабораторної роботи: вивчити концепцію та функціональні можливості сучасних професійних програмних систем візуалізації на прикладі пакету MineSet; навчитися застосовувати концепцію візуалізації даних для проведення „розвідувального” аналізу з метою забезпечення користувачача швидким та якісним розумінням контексту інформації.

Завдання до лабораторної роботи:

- ознайомитися з основними характеристиками та компонентами системи MineSet – як одного з лідерів на ринку систем візуалізації;
- з запропонованого переліку висхідних даних (Додаток №1 до ЛР) обрати та завантажити файл даних із предметної області, ня якій спеціалізується студент; імпортувати обраний файл в систему MineSet;
- провести необхідні операції над файлом даних на панелі Data Transformations вікна Tool Manager;
- провести „розвідувальний” дейтамайнінг інструментами візуалізації вкладинки Viz Tools панели Data Destinations вікна Tool Manager та сформулювати власні висновки щодо наявності та суті прихованих тенденцій та шаблонів;
- роздрукувати згенеровані системою звіти та графіки, захистити роботу перед викладачем.

Стисла характеристика програмного середовища виконання лабораторної роботи.

Сьогодні на ринку існує цілий ряд пакетів, що володіють розвиненими дейтамайнінговимі інструментами, але не так багато продуктів, які при цьому володіють потужними інструментами візуалізації. MineSet має унікальне поєднання обох цих технологій з упором на інструменти візуалізації, що дозволяють аналізувати дані за допомогою різних видів їх подання.

Продукт MineSet сьогодні поставляється компанією Purple Insight (а перші версії даного продукту були розроблені Silicon Graphics в 90-х роках). Компанія Purple Insight (http://www.purpleinsight.com/aboutus/) була організована в 2003 році для просування і розвитку MineSet, а також для надання асоційованих сервісів. Продукт є інтегрованим середовищем програмних інструментів для дейтамайнінгу для виявлення прихованих закономірностей (у вигляді значущих особливостей, кореляцій і тенденцій) і візуалізації даних. Технології, закладені в пакет MineSet підвищують ефективность процесів дейтамайнінгу стосовно різних областей досліджень, і в першу чергу у сфері бізнес-аналітики.

К особенностям программы следует отнести: масштабируемость, позволяющую обрабатывать большие объемы данных, многоплатформенность — поддержку широкого спектра баз данных и операционных систем, а также открытую архитектуру (через технологію ActiveX).

До особливостей програми слід віднести: масштабованість, що дозволяє обробляти великі об'єми даних, мультиплатформеність (підтримку широкого спектру баз даних і операційних систем), а також відкриту архітектуру (з використанням ActiveX).

Наразі доступні чотири версії MineSet:

- MineSet DV, MineSet 100M, MineSet 500M — працюють під управлінням Microsoft Windows;
- MineSet Enterprise Server — працюють під управлінням Microsoft Windows, Microsoft Windows Server и Silicon Graphics (SGI) IRIX;
- MineSet Enterprise Client — працюють під управлінням Microsoft Windows та Silicon Graphics (SGI) IRIX.

Функциональность	MineSet-продукт			
	DV	100M	500M	Enterprise
Неограниченная возможность трансформации и визуализации данных	+	+	+	+
Связь с БД	+	+	+	+
Аналитика	-	+	+	+
Множественные клиенты	-	-	-	+
Ограничения на количество записей Analytics Data Capacity	Нет данных	100 тыс. записей	500 тыс. записей	Неограниченно

Всі вищеперелічені версії MineSet це масшабовані клієнт-серверні рішення, що використовують трьохрівневу архітектуру.

Перший рівень - клієнт, який включає Tool Manager і інструменти візуалізації. Tool Manager - графічний інтерфейс (GUI), через який користувач взаємодіє зі всіма можливостями системи MineSet. Інструменти візуалізації використовуються, щоб візуалізувати початкові дані і результуючі дані алгоритмів дейтамайнінга. Після виклику інструменту візуалізації за допомогою Tool Manager, користувач може взаємодіяти безпосередньо з цим інструментом і пересилати інформацію від нього до інших інструментів.

Другий рівень архітектури MineSet - сервер, який включає процес Data Mover і алгоритмічне забезпечення звичайного дейтамайнінгу. Data Mover - компонента, що забезпечує доступ до бази даних і перетворення даних для інших компонент. Вона „витягує" дані з джерела даних, трансформує їх і управляє їх переміщенням від однієї компоненти MineSet до іншо]. Закладені в сервер MineSet алгоритми дейтамайнінгу використовуються для того, щоб генерувати моделі, які можуть бути використані для нових наборів даним або бути візуалізіовані.

Третій рівень архітектури MineSet - джерело даних, яке звичайно є програмно-апаратним комплексом для зберігання та підтримки функціонування баз даних користувачів. Це може бути і автономний файл Excel, і корпоративна база даних (під управлінням Oracle, Sybase, Informix і т.д.).

Згідно закладеної в MineSet концепції, рівні архітектури не прівязанні до конкретного програмного або апаратного забезпечення, тобто всі три рівні можуть виконуватися і на окремій PC під управлінням ОС Windows.

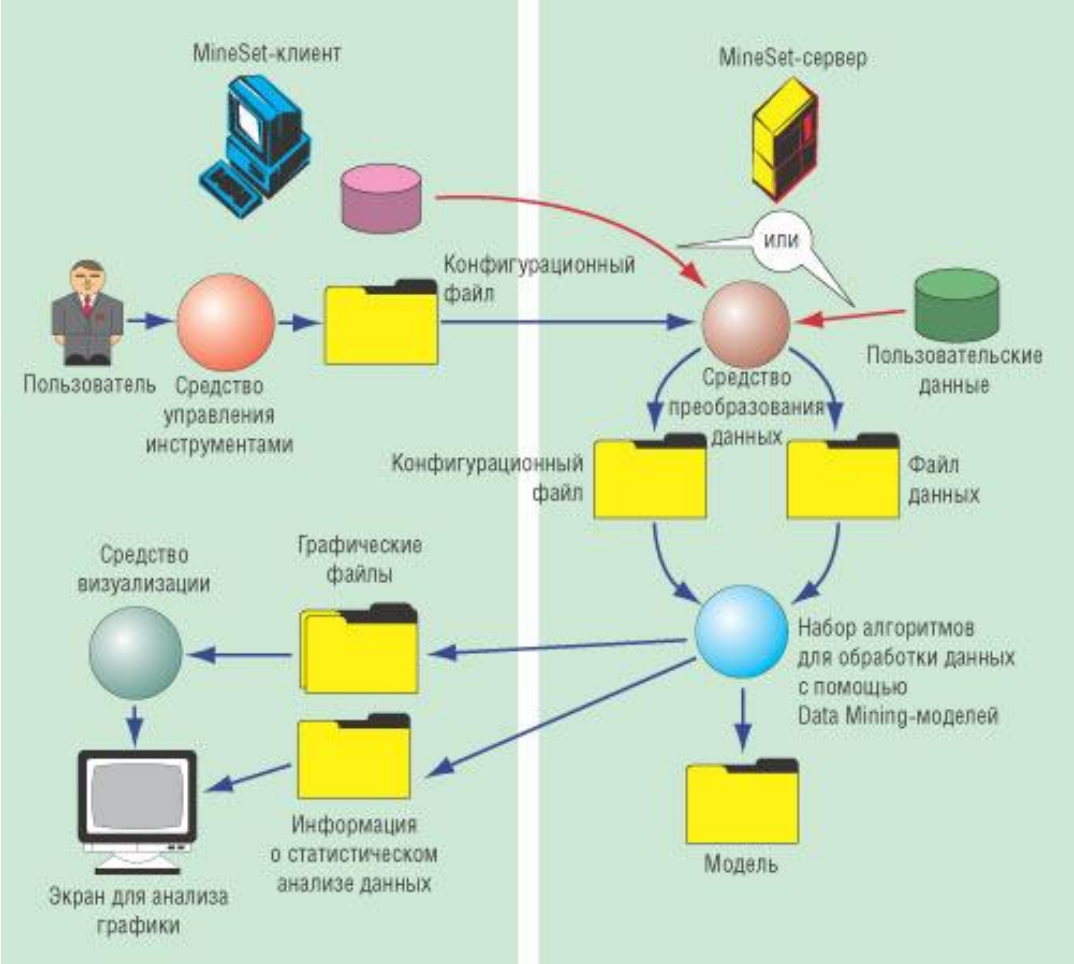

Рис. Технологічний процес дейтамайнінгу в MineSet

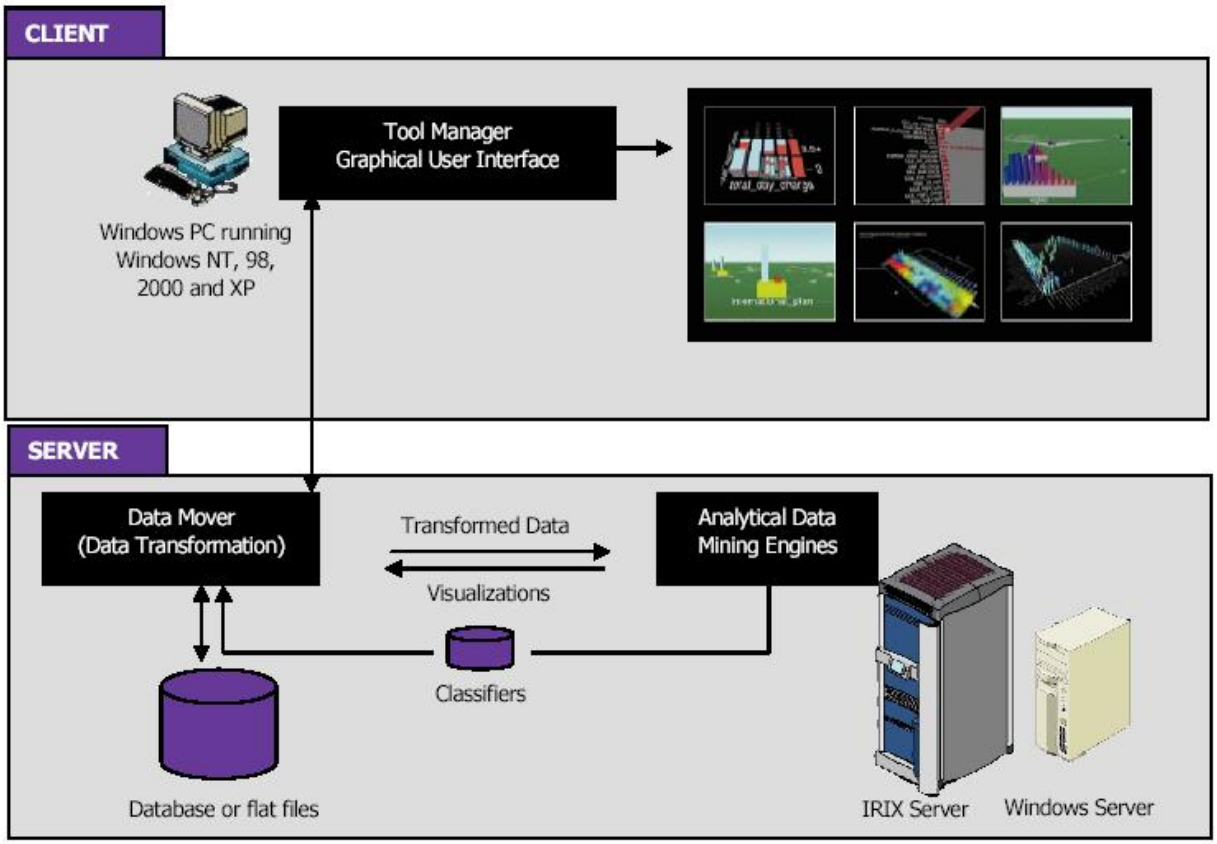

Рис. Трьохрівнева клієнт-серверна архітектура MineSet

Розглянемо докладніше функціональності керуючого модуля Tool Manager.

Tool Manager - це інтерактивний графічний інтерфейс, за допомогою якого користувач отримує доступ до всіх можливостей і інструментів MineSet в рамках єдиного інтегрованого середовища. Перш за все, Tool Manager дозволяє встановити зв'язок з сервером і специфікувати базу або файл, що містять початкові дані, а також визначити дисципліну доступу і маніпулювання даними. Для реляційних СУБД Oracle, Informix і Sybase, а також ASCII-файлів реалізована пряма вбудована процедура доступу; проте можна визначати і користувацькі SQL-запити, що доречно тоді, коли інформаційні сховища реалізовані в особливий спосіб або знаходяться під управлінням „закритої" СКБД (що не підтримується MineSet безпосередньо). Набір перетворень, корисних при генерації вхідних файлів для кожного з інструментів аналітичного і візуального аналізу, вельми широкий (описаний нижче). Доречно також задіювати засоби протоколювання цих перетворень. Зрештою, Tool Manager створює файли конфігурації, задаючі дисципліну роботи для кожного з інструментів аналізу.

Зокрема, саме відповідно до інформації, що міститься в переданому на сервер файлі конфігурації, процес DataMover здійснює доступ до даних, проводить вибірку і перетворення, ініціалізує роботу інструментів аналітичного data mining (запускаються на сервері), і повертає дані на клієнтську станцію для розподілу їх по візуальних інструментах. Останні запускаються на клієнтській станції самим Tool Manager, який знову ж таки через відповідні файли конфігурації і визначає, які дані і як візуалізуються кожним з відповідних інструментів. Нарешті, є можливість запам'ятовувати і, при необхідності, відновлювати як одержані дані, так і хід управління сесією (її сценарій).

По суті цей сценарій є не що інше як порядок генерації і використання всієї сукупності файлів конфігурації, що специфікує послідовність дій, яка динамічно породжується та запускається на виконання. Слід зазначити, що не досвідченому в комп'ютерних технологіях користувачу такого роду сценарій краще одержувати в готовому вигляді, що зовсім не означає пасивність користувача: адже у тому-то і сенс цієї технології, що у користувача є можливість зосередитися на змістовній інтерпретації знання, яке здобувається, що дозволяє проводити справжній розвідувальний аналіз даних.

Вікно Tool Manager складається з двох вкладинок: Single Transformation and Data Destination View та вкладинки History of Operations View. Основною є перша вкладинка, яка в свою чергу складається з трьох областей:

Data Transformations (містить кнопки для всіх опаерації з трансформації вхідних файлів баз даних);

Data Destinations (надає доступ до різноманітних інструментів MineSet);

Status (відображає інформацію щодо статусу поточних процесів та операцій MineSet).

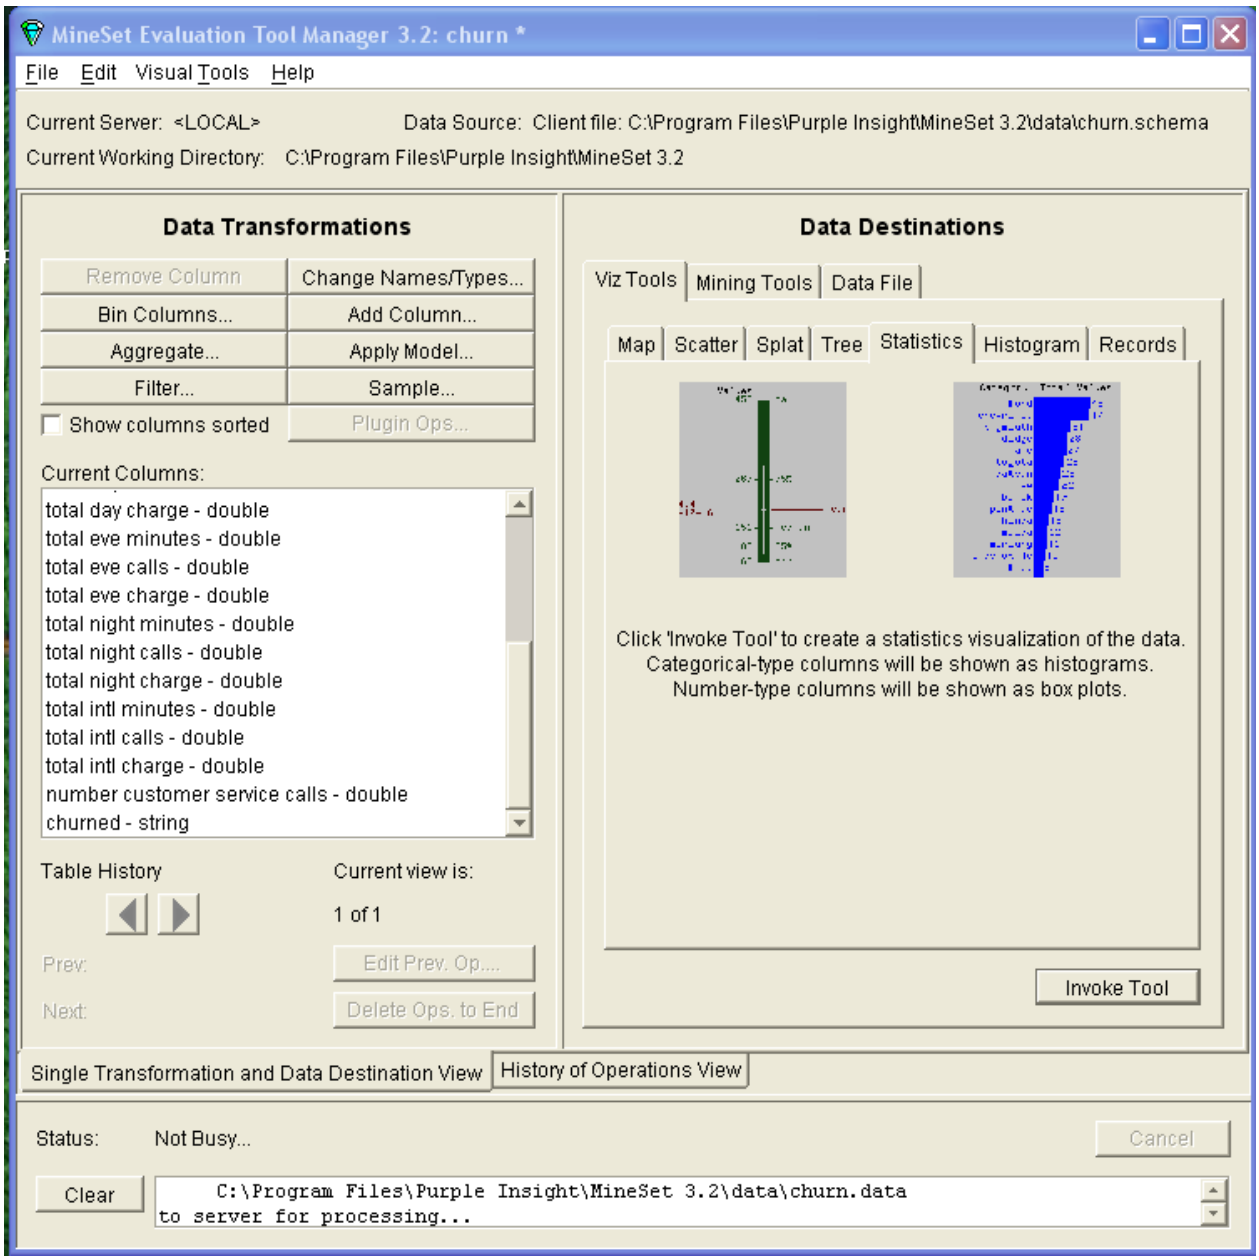

Рис. Вкладинка Single Transformation and Data Destination View вікна Tool Manager

Користувач у бідь-який момент може перейти до вкладинки History of Operations View, яка відображає історію всіх попередніх дій та операцій користувача у вигляді блок-схеми, яку можна редагувати (для створення сценаріїв).

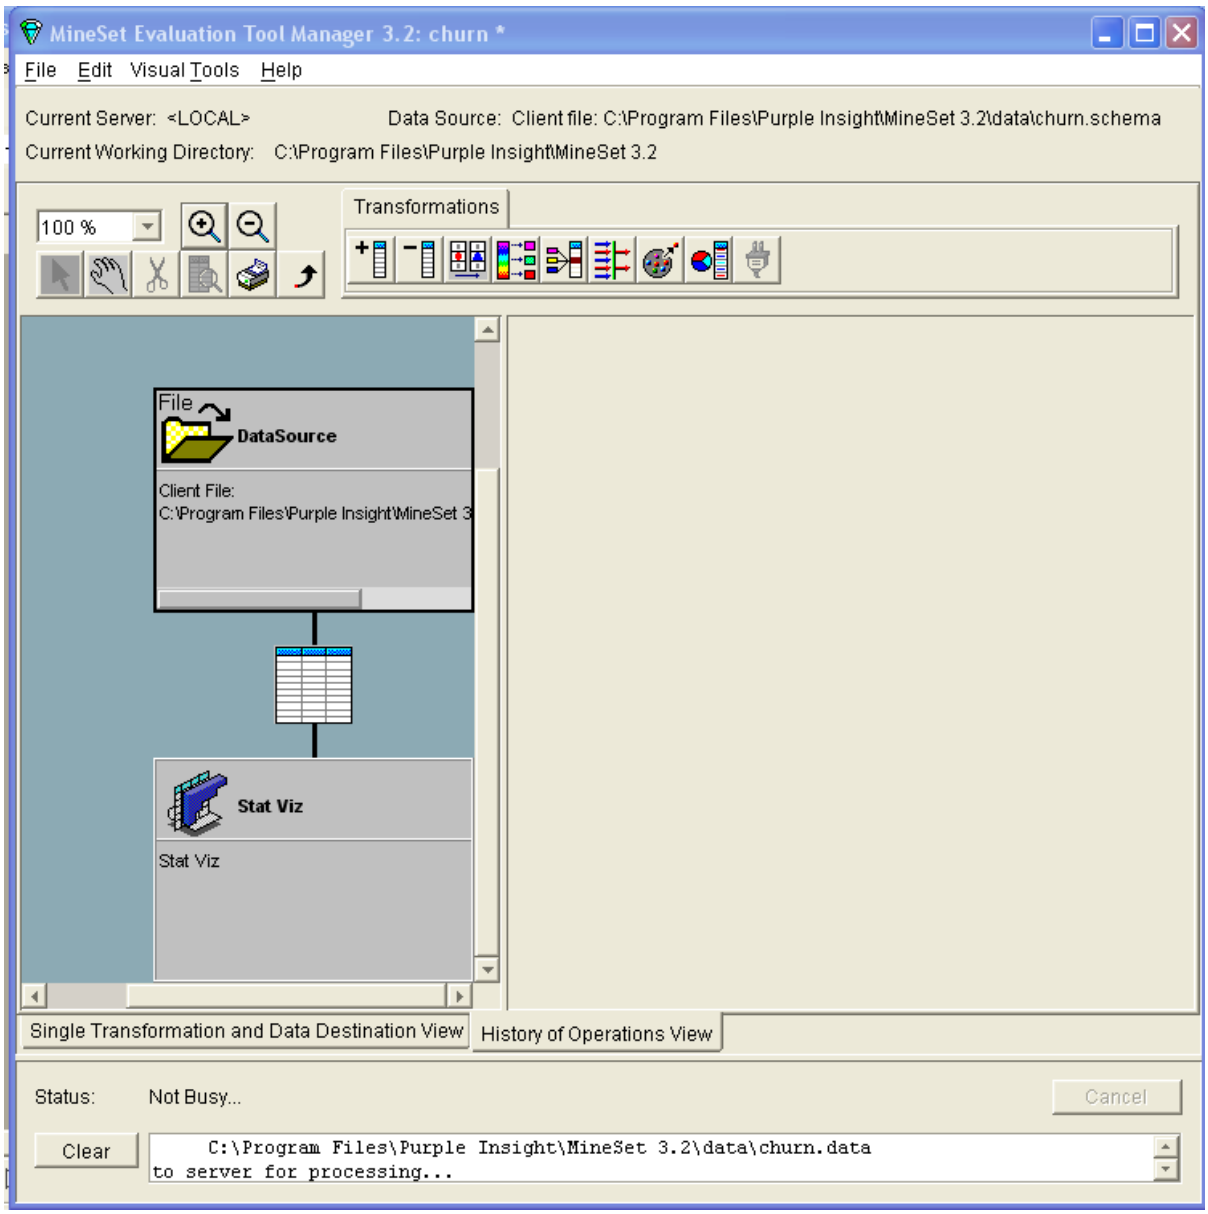

Панель Data Transformations головного вікна Tool Manager містить кнопки для запуску операцій над файлом даних:

- Removing a Column
- Adding a Column
- Aggregating Data (з генерацією індексованих масивів з використанням функцій SUM, AVERAGE, MIN, MAX, COUNT)
- Applying a Model
- Binning Columns
- Changing Column Names and Data Types
- Filtering Data
- Sampling Data

Панель Data Destinations головного вікна Tool Manager містить три вкладинки:

- Viz Tools
- Mining Tools
- Data File (параметри вихідного файлу)

Як було викладено вище, MineSet володіє досить розвиненими стандартними характеристиками пакету дейтамайнінгу, і саме на вкладинці Mining Tools панелі Data

Destinations відображені пропоновані розробниками mineSet п'ять алгоритмів інтелектуальні обробки даних (результаті яких надалі також можна візуалізувати):

- Association Rules (One-toone, Multiway)
- Cluster (K-means, Iterative K-means)
- Classifiers (Decision Tree, Option Tree, Evidence Inducer, Decision Table)
- Regression Tree
- Column Importance Tool (automatic attribute selection)

Засоби візуалазациі MineSet, що відображаються на вкладинці Viz Tools панелі Data Destinations навпаки, не використовують ніяких алгоритмів для аналізу даних, а відкривають перед користувачами перспективи інтерактивного дослідження даних на базі специализірованних інструментів візуалізації, яка дозволяє швидше виявляти основні значущі тенденції і залежності.

- Map Visualizer (ландшафтний візуалізатор) дозволяє представити дані у вигляді тривимірного ландшафту - стовбчатих діаграм, з індивідуальними висотою і кольором, що дозволяє показувати кількісні і реляційні характеристики просторово орієнтованих даних і швидко ідентифікувати в даних як тенденції і взаємозв'язки, так і аномалії. Map Visualizer дозволяє аналітикам спостерігати за розгортанням безлічі даних, а також одночасно генерувати анімаційні презентаційні ролики. При роботі з Map Visualizer доступні всі операції навігації через ландшафт: панорамування, обертання в 3D-просторі, масштабування з укрупненням цікавої області тощо. Причому користувач може виконувати як операцію drill-down (збільшення масштабу карти) з метою отримання деталізованої інформації про специфічні області даних, так і операцію drill-up (зменшення масштабу карти), ***щоб отримати загальну уяву як певні локальні області даних вбудовані в навколишнє середовище***.

- Scatter Visualizer (дисперсійний візуалізатор) - засіб для аналізу даних в багатьох вимірюваннях. До звичайної 3D-системи координат додаються додаткові виміри, що асоціюються, наприклад, з розміром і кольором елементів даних, це дозволяє візуально досліджувати дані у восьми вимірюваннях. У тривимірному просторі, доповненому координатною сіткою, можна орієнтувати зображення для акцентування певного вимірювання. Можна масштабувати величини деяких змінних для надання їм більшої значущості. Існує можливість фільтрації зображення для відображення даних, що задовольняють певним критеріям. Scatter Visualizer - ***ідеальний засіб для аналізу аномальних „викидів" даних, що виходять за рамки загальних закономірностей***.

- Splat Visualizer дає можливість представити якісні дані зі складними ***взаємозв'язками в багатовимірному просторі використовуючи технологію категоризованих графіків, кольорові маркери.***

- Tree Visualizer (візуалізатор дерев рішень) дозволяє представити ієрархічно організовану інформацію у вигляді тривимірного ландшафту, тобто вести огляд всієї безлічі даних або її частини. Кількісні і реляційні характеристики даних робляться наочними за допомогою ієрархічно з'єднаних вузлів. У кожному вузлі будуються стовпці, висота і колір яких відповідають значенням атрибутів даних. Лінії, що сполучають вузли, показують взаємозв'язки множини даних з підмножинами. Візуалізатор дерев рішень дозволяє аналізувати вельми складні моделі. Кожен вузол в дереві відображає точку ухвалення рішення. Залежно від того, як модель оцінює дані по відношенню до рішення, ви вибираєте відгалуження вліво або управо - залежно від відповіді на деяке питання. У міру того як користувач „пролітає" над деревом, йому відкривається все більше інформації.

- Statistics Visualizer дає в графічному форматі візуальне представлення підсумку базової статистичної обробки даних (включаючи математичне очікування, середньоквадратичне відхилення, мінімум та максимум тощо).

- Histogram Visualizer (візулізатор гістограм) автоматично будує гістограму для всіх атрибутів з неперервними кількісними значеннями та відправляє результати до Statistics Visualizer, при чому користувач може не тільки встановити кількість елементів дискретизації для кожного атрибуту, але й встановіті корекцію (trimming fraction) задля вилучення екстремальних випадків та інформаційного „шуму”.

- Record Viewer є не просто інструментом швидкого переглядання початкових даних, але і має потужні інструменти їх фільтрації, сортування, генерування вихідного html коду тощо.

В звіті по даній лабораторній роботі обов’язково повинно міститися:

- роздруківка вкладинки Single Transformation and Data Destination View вікна Tool Manager з підключеним сервером та джерелом даних;
- роздруківка завантажених вхідних даних в середовищі Record Viewer
- роздруківка вкладинки History of Operations View вікна Tool Manager
- роздруківка результатів проведеного „розвідувального” дейтамайнінгу всіма наявними інструментами візуалізації вкладинки Viz Tools панели Data Destinations.

ДОДАТОК 1.

Список ресурсів, що містять ON-LINE банки даних для завантаження в пакет MineSet та подальшого проведення розвідувального аналізу даних в ЛР:

Data Sets from SGI
UCal Irvine Machine Learning Repository
Criminal Justice Data a NACJD
UCI KDD Archive: Data Sets
Social Science Data
Cancer Data
Data Sets
IDS data sets
Data Sets for Data Mining
Competition Data Set
UCI Machine learning repository
Quest data repository
KDNuggets