Практическая работа №1. Знакомство с системой WizWhy

ЧАСТЬ 1. Учебно-тренировочная.

1. Загрузка и управление данными.

Первое, что нужно сделать при работе с WizWhy, это загрузить анализируемый файл данных. Здесь имеется несколько возможностей:

- Вы можете подготавливать и читать файлы ASCII.
- Вы можете напрямую работать с файлами dBase(*.dbf), MS Access (*.mdb), Oracle и таблицами MS SQL.
- Вы можете воспринимать наборы данных посредством ODBC (Open Database Connectivity).

Для начала работы с процедурой загрузки следует, прежде всего, обратиться к закладке Basic Data в окне диалога с именем текущего проекта (рис.1). Здесь в поле Open Data of Type нужно указать тип загружаемых данных.

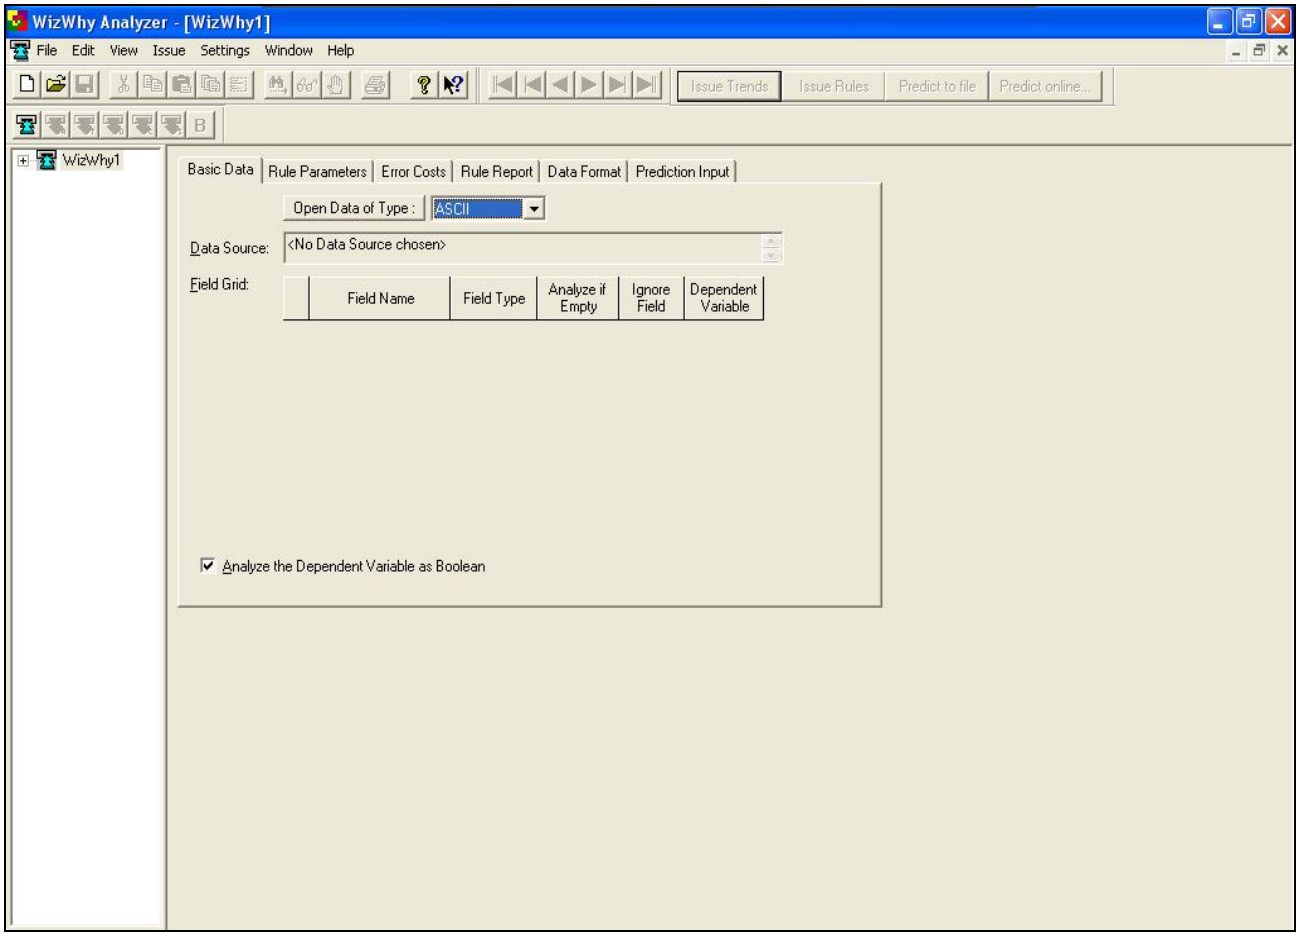

Рис.1. Начало работы с системой WizWhy

Для примера возьмём таблицу с данными по ультразвуковой диагностике почек в текстовом формате ASCII (разделителями колонок является знак табуляции, в первой строке таблицы данных записаны имена переменных). Укажем требуемый тип данных и в появившемся окне диалога выберем файл USR.txt – на экране выдаётся окно диалога системы WizWhy для редактирования и преобразования текстовых файлов (рис.2).

В поле Record Type (тип записи) устанавливаем переключатель в положение Delimited (данные с разделителем) и ставим флажок в позиции First record for fields names, говорящий о

том, что имена переменных располагаются в первой строке таблицы данных. В поле Field Delimiters (разделитель) ставим флажок в позиции Tab (знак табуляции).

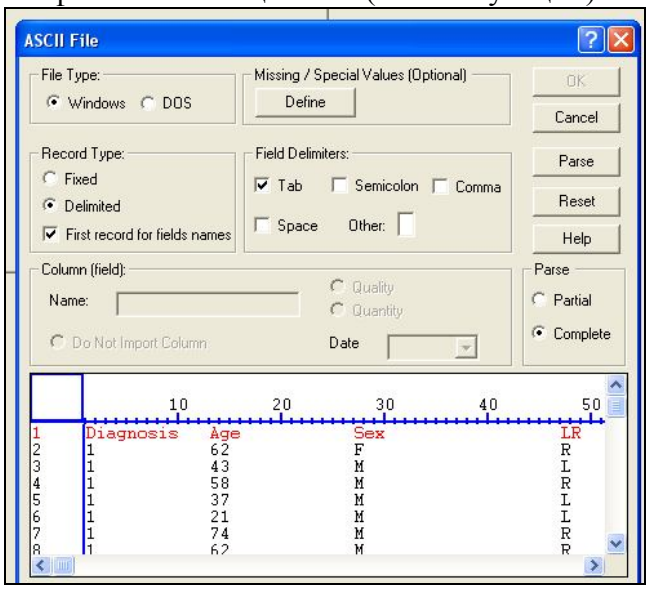

Рис.2. Диалоговое окно для чтения данных в текстовом формате

Нажимаем кнопку Parse, после чего система производит автоматический грамматический разбор данных. Просматриваем результаты этого разбора и при необходимости вносим коррективы – в поле Column (field) предоставляются возможности для изменения имён и типов переменных, а также отказа от импорта каких-либо колонок. Нажимаем OK. Система импортирует данные для дальнейшей обработки, что отражается в диалоговом окне для управления данными Basic Data (рис.3).

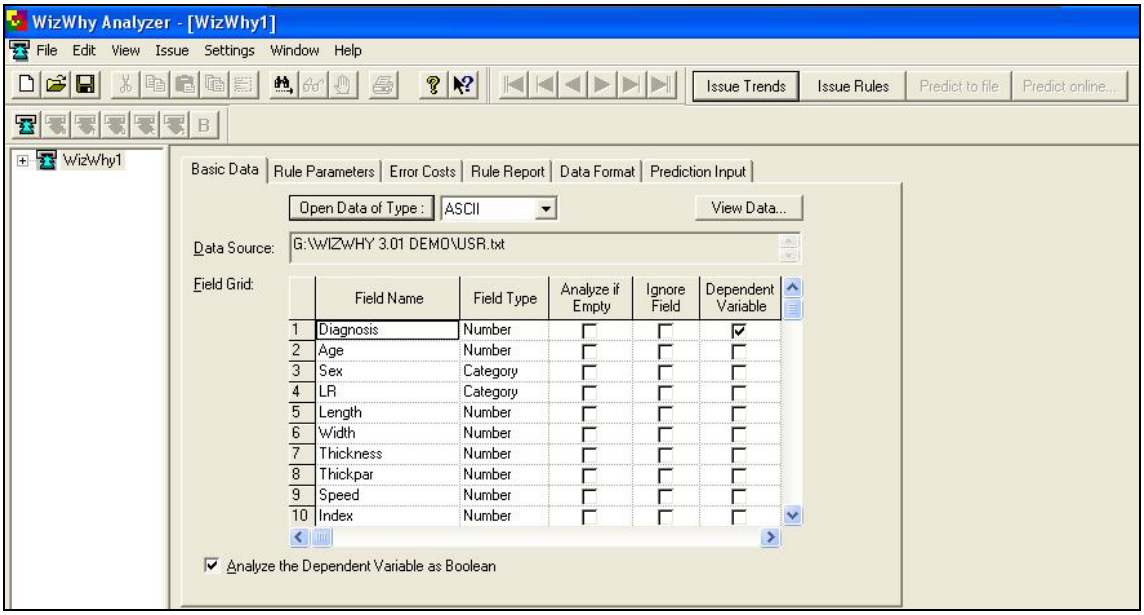

Рис. 3. Окно диалога для управления данными

В поле Data Source указываются местоположение и имя файла, из которого были импортированы данные. Кнопка View Data предназначена для вызова окна для просмотра загруженных данных (в нём демонстрируются 100 первых строк таблицы) данных. В поле Field Grid отображаются имена и типы введённых переменных и предоставляются возможности проведения следующих операций:

- Назначение целевой, или так называемой зависимой (dependent) переменной. Это переменная, значения которой будут связываться с помощью if-then-правил со значениями так называемых независимых (independent) переменных. В нашем случае такой целевой переменной является Diagnosis – выставляем флажок в соответствующей позиции колонки Dependent Variable.
- Модификация переменных. В колонке Field Name можно редактировать имена переменных. Для этого нужно щёлкнуть на соответствующей позиции и ввести новое имя. Кроме этого, в позициях колонки Field Type можно изменять тип переменной. Например, заменить тип Category (категориальный) на Number (количественный) или Date (дата) в формате День-Месяц-Год (Год-Месяц-День) и т.п. Здесь заметим, что в зависимости от выбранного типа данных в дальнейшем к переменной применяются различные процедуры обработки.

В системе WizWhy предусмотрен также случай, когда пропуски в таблице данных (пустые ячейки) представляют собой самостоятельные информативные события. Для учёта подобных пропусков в значениях какой-либо переменной ставится флажок против неё в колонке Analyze if Empty. В свою очередь, если имеется необходимость исключить переменную из анализа, нужно выставить флажок в колонке Ignore Field.

В нашем примере две переменные имеют категориальный (Category) формат – целевой признак Diagnosis, признак Sex (пол пациента) и признак LR (левая или правая почка.) Остальные переменные (Age (возраст), Length (длина почки), Width (ширина почки), Thickness (толщина почки), Thickpar (толщина паренхемы), Speed (средняя скорость кровотока), Index (индекс резистентности) и Accel (ускорение артериального потока в систолу)) - количественные (Number).

2. Задание параметров процедуры поиска правил

В системе WizWhy целевой признак разделяет всё множество объектов на две части. Это делается следующим образом.

Если целевая переменная является категориальной, WizWhy просматривает все объекты (записи) и отбирает те из них, для которых целевая переменная имеет выбранное значение. Отобранные таким образом объекты составляют первую группу. Правила, характерные для данной группы, называются if-then-правила. Оставшиеся объекты составляют вторую группу, и для этой группы характерные правила обозначаются как if-they-NOT-правила.

Если целевой признак является количественным, пользователь должен указать область значений этого признака. Правила if-then будут определяться для этой указанной области. В свою очередь, if-they-NOT-правила будут описывать объекты, не попавшие в выделенную область.

В рассматриваемом нами практическом примере целевой признак категориальный. Он принимает три значения: 1 – в классе «здоровая почка», 2 – в классе «множественные кисты» и 3 – в классе «гидронефроз». Будем искать в данных if-then-правила для объектов с диагнозом «множественные кисты». Для этого с помощью закладки Rule Parameters (параметры правил) войдём в соответствующее окно диалога и в поле Predicted Value выставим значение «2».

<u>Примечание: Если при попытке выполните вышеуказанный пункт задания программа WizWhy «вылетает», то следует сменить тип переменной «Diagnosis» с категориального на количественный и установить следующие значения полей «More than» и «Less or equal than» (см. рис. 4).</u>

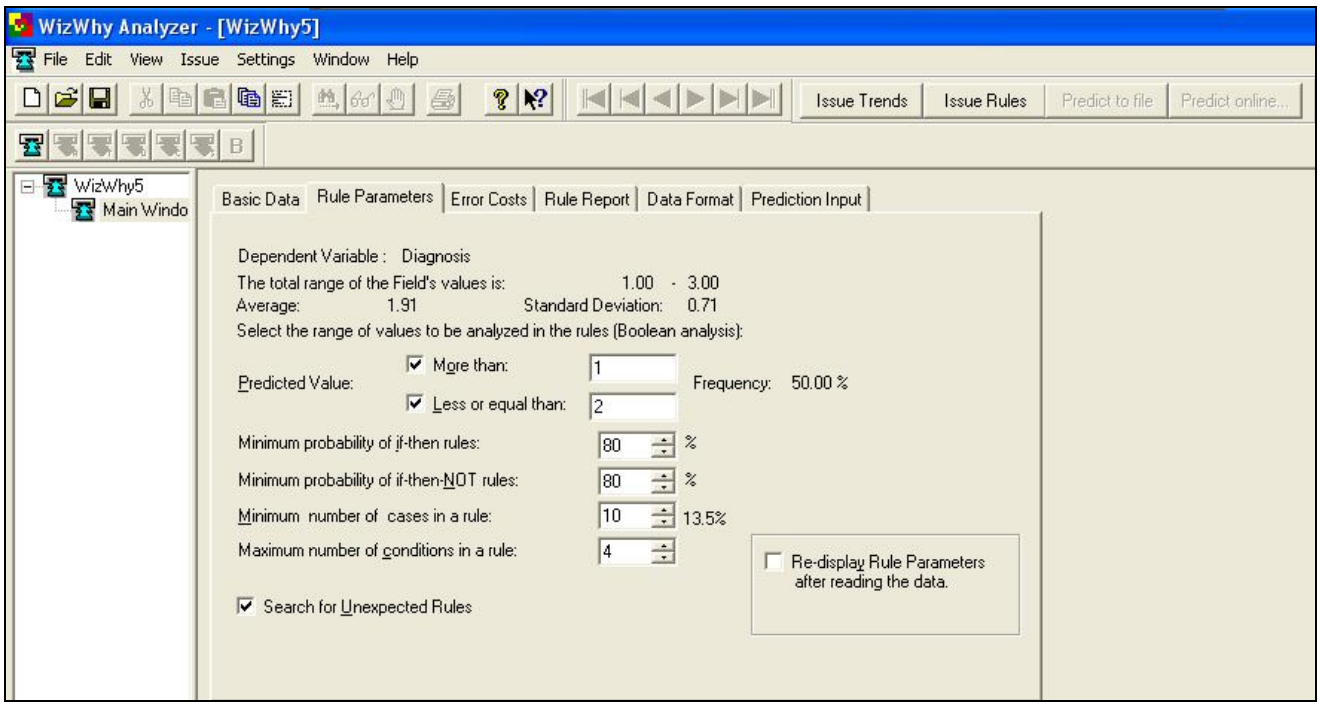

Рис. 4.

Последующие действия выполняются вне зависимости от того, «вылетала» программа или нет.

После задания области значений целевой переменной или, как в нашем случае, её одного значения система WizWhy читает данные и вычисляет простые статистики, которые могут быть использованы в дальнейшем анализе. Так, например, справа от поля Predicted Value система выводит значение частоты, с которой в анализируемых данных встречается значение Diagnosis = 2. Как указывают авторы, чтение больших наборов данных способно занимать много времени. Пользователь может прекратить процесс чтения, нажав кнопку Cancel на специальной панели. В этом случае дальнейшему исследованию подвергается только та информация, которая успела прочитаться. Но при желании процесс поиска данных можно повторить.

Следующим шагом является задание собственно параметров правил, которые будут искаться в прочитанных данных. Сюда, прежде всего, относят Minimum probability of if-then rules (минимальная вероятность if-then-правил) и Minimum probability of if-then-NOT rules (минимальная вероятность if-then-NOT-правил). Эти параметры есть ни что иное, как **точность** правила. Поставим в соответствующих полях окна диалога одинаковые значения указанных вероятностей 80% процентов. Это означает, что системе WizWhy формулируется требование обнаружить правила, которые будут ошибаться не более чем в 20% случаев (имеются в виду ошибки на анализируемой выборке).

В принципе, можно задавать любые значения минимальных вероятностей от 0 до 100%. Но следует хорошо представлять, что, задав слишком низкий уровень точности, мы получим большое количество правил, среди которых будет много малоинформативных компонентов. В свою очередь, выставив требование 100%, мы, скорее всего, не получим вообще ничего.

Ещё одним важным параметром служит Maximum number of conditions in a rule (максимальное число условий в правиле). Это максимальное количество элементарных логических событий в одном правиле. Хотя авторы ничего не говорят о предельном значении данного параметра, установлено, что оно равно 6.

Следующим параметром, который необходимо задать для работы процедуры поиска правил, является Minimum number of cases in a rule (минимальное число объектов в правиле). Выставим здесь значение 10, обозначив тем самым наше желание обнаружить в данных правила, которые распространяются не менее чем на 10 объектов. Нижний предел составляет 4 объекта.

3. Окно Rule Report

Настройки этого окна (см. рис.5) касаются способов выдачи результатов. Во-первых, нужно ввести параметр Maximum number of rules to be displayed (максимальное количество отображаемых правил). Этот параметр не влияет на работу процедуры поиска правил. Он предназначен только для ограничения количества правил, выдаваемых в отчёт (Rule Report). Далее следует указать способ сортировки правил в отчёте (по уровню значимости – Significance level, по точности – Probability, по количеству объектов – Number of cases). В поле Present examples where (представить примеры) можно выразить желание посмотреть примеры работы выявляемых правил. Если поставить флажок в позиции Rule in effect, то система будет формировать в отчёте для каждого правила список номеров объектов, для которых правило не ошибается. Длина списка ограничивается заданным числом. Соответственно, флажок в позиции Rule in not effect запрашивает у системы выдачу списка номеров объектов, на которых какое-либо правило работает с ошибкой.

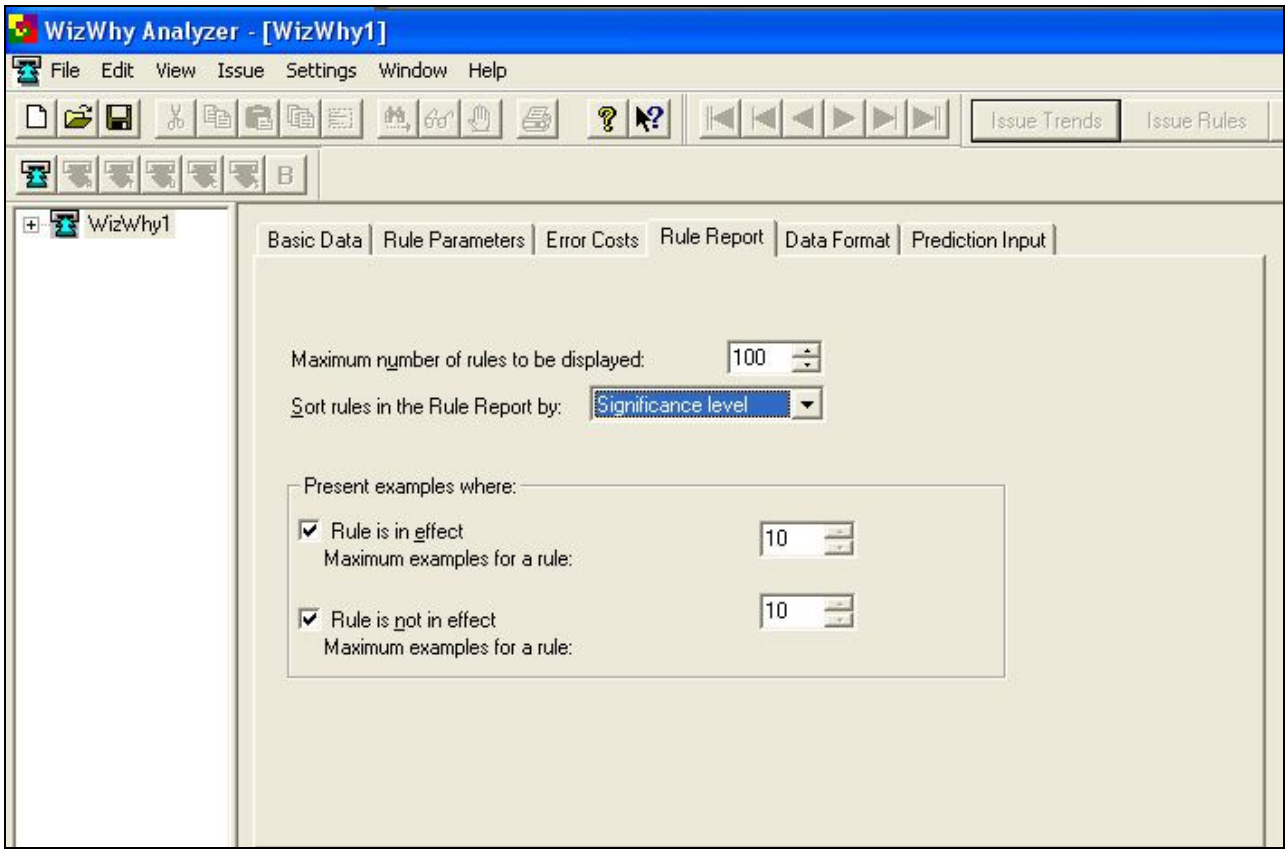

Рис.5

4. Работа с другими окнами диалога

Окно диалога Data Format предназначено для задания и корректировки формата информации, с которой работает WizWhy (рис. 6). Прежде всего, сюда относится формат данных. В поле number and Currency Format имеется возможность задавать количество цифр и виды разделителей в числовых и денежных данных, а в поле Data Format выбирать формат для записи дат.

Кроме того, в нижней части окна диалога предусмотрены параметры, выбор которых определяет место выдачи отчёта о результатах работы системы (на принтер, на экран, в текстовый файл и т.д.). В поле Subheading заносится подзаголовок отчёта. Нажатием кнопки Font в правом нижнем углу вызывается окно диалога для выбора используемых шрифтов.

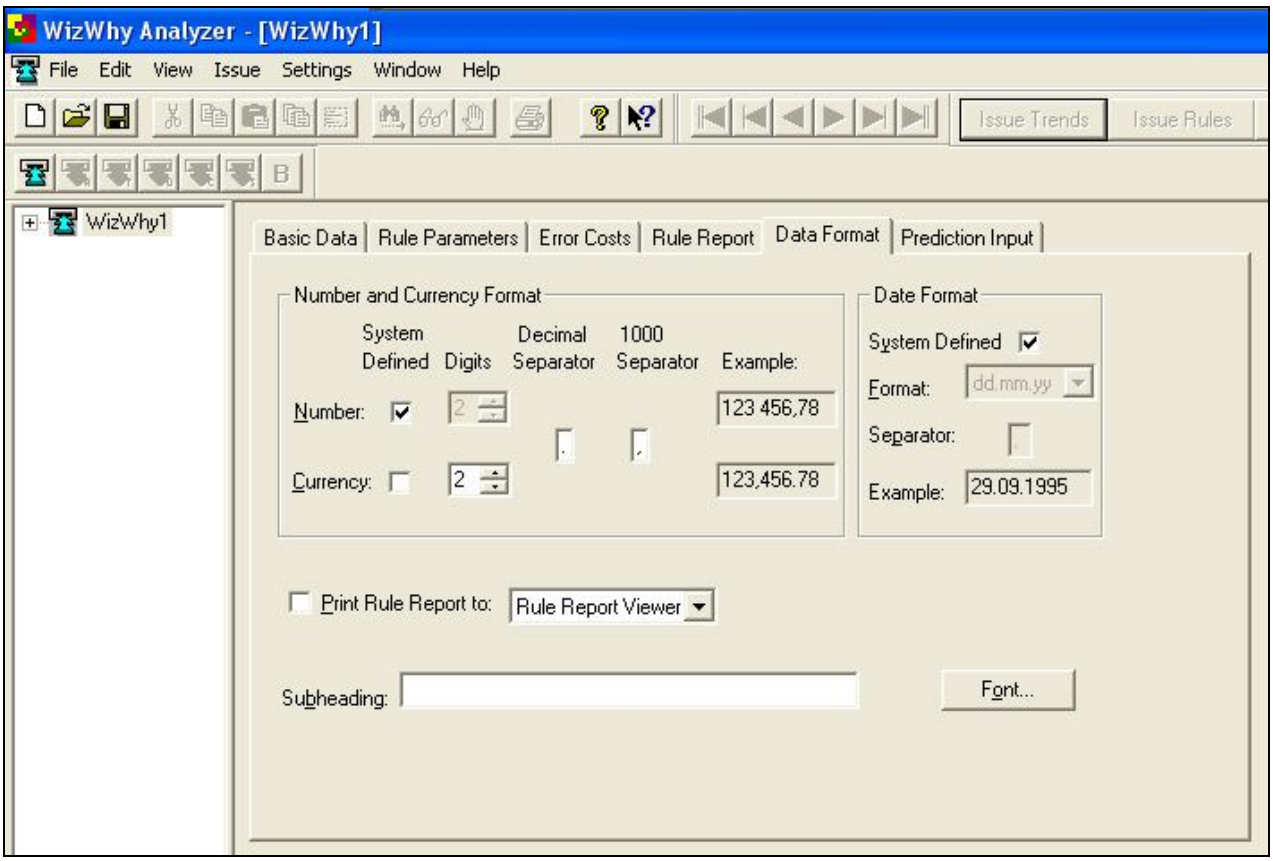

Рис. 6

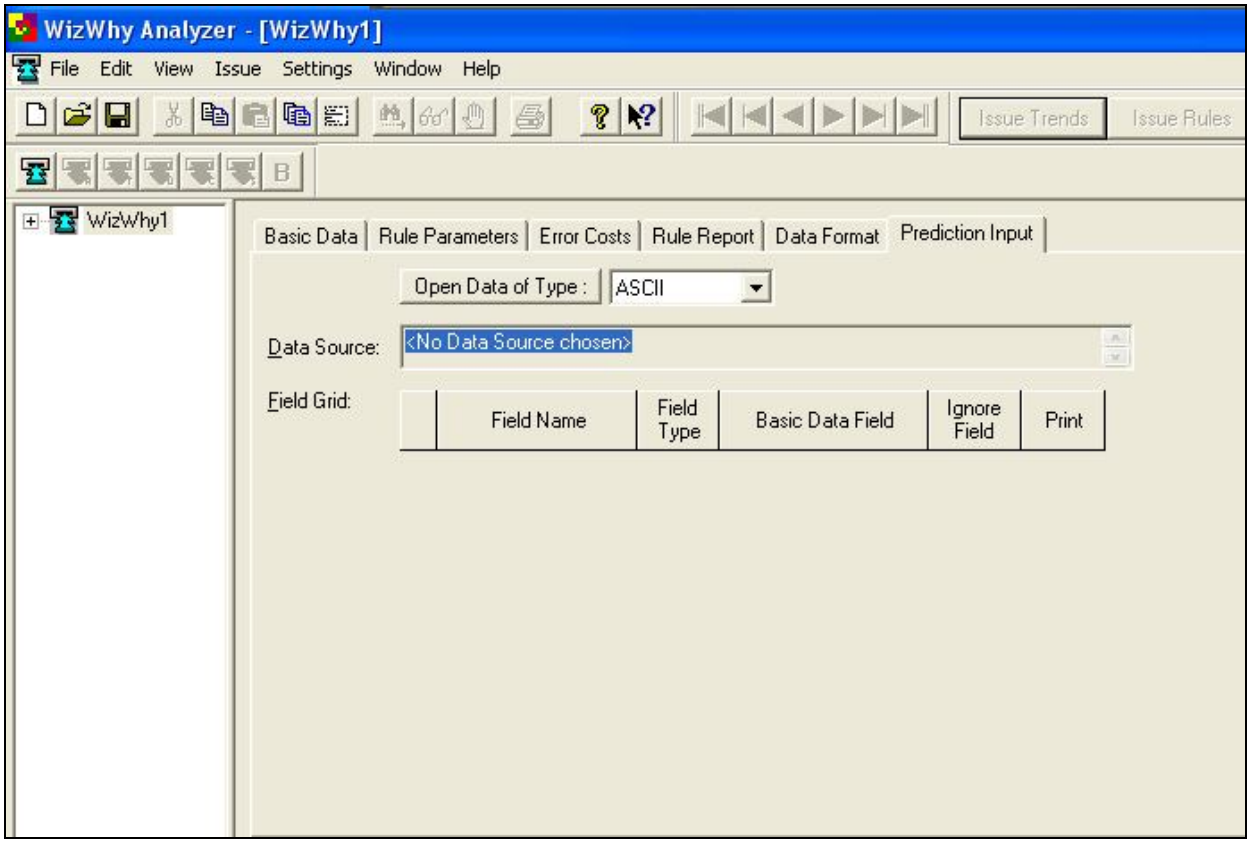

Рис. 7

Крайнее диалоговое окно – Prediction Input – предназначено для ввода, просмотра и коррекции внешних данных, на которых требуется проверить действие найденных правил. Оно

изображено на рис.7. Работа с этим окном аналогична работе с уже рассмотренным диалоговым окном Basic Data.

В окне Error Costs (стоимость ошибок) требуется ввести соответствующие значения по отдельности для двух видов ошибок: пропуска объектов (Cost of miss) и ложной тревоги (Cost of false alarm) (рис. 8).

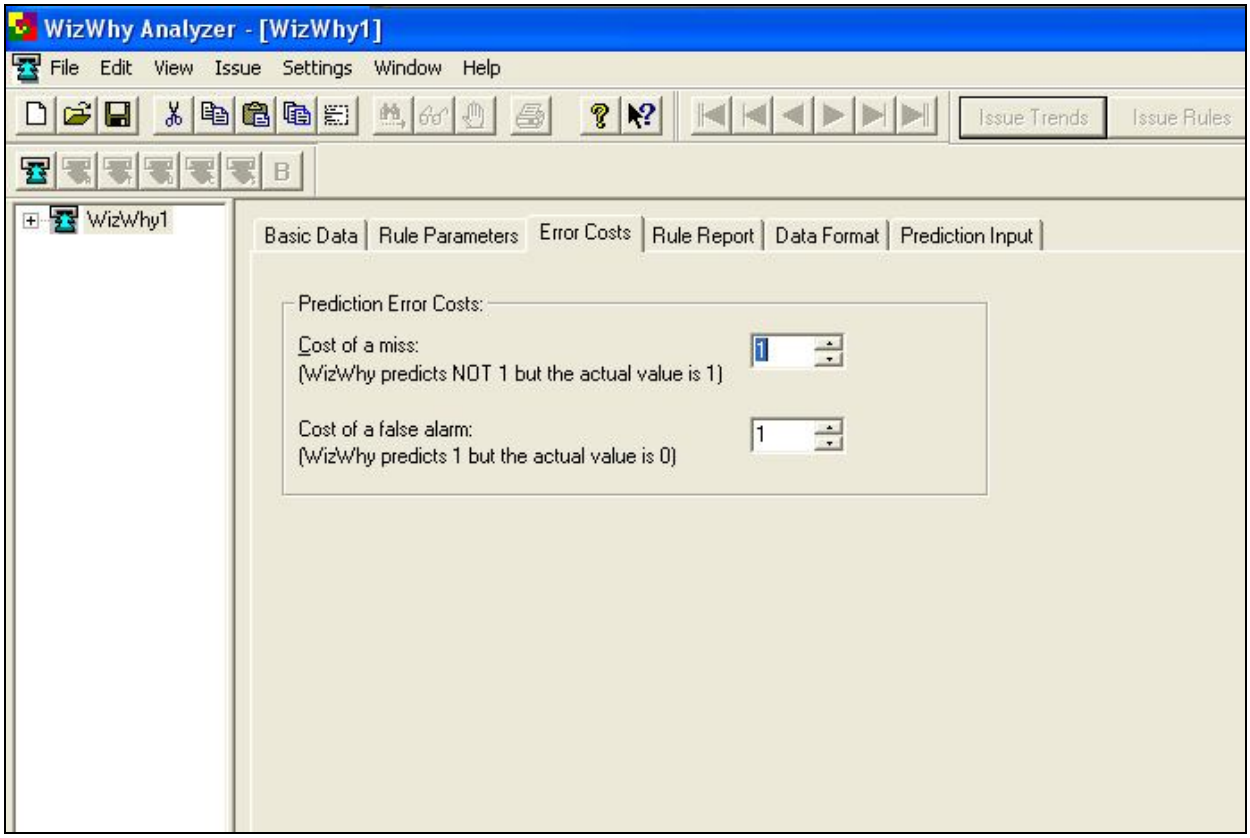

Рис. 8

По умолчанию эти значения равны «1». Учёт различной стоимости указанных ошибок может оказаться весьма ценным при решении практических задач.

5. Результаты работы системы

После внесения необходимой информации в рассмотренные выше окна диалога можно приступить к поиску правил в загруженных данных. Для этого нужно нажать кнопку Issue Rules (выдача правил) – система WizWhy выдаёт три отчёта:

- Отчёт о правилах (Rule report), в котором перечисляются обнаруженные правила с указанием их характеристик.
- Отчёт о трендах (Trend report), в котором представлены результаты сегментации отдельных признаков.
- Отчёт о неожиданных правилах.

Рассмотрим указанные отчёты более подробно.

6. Отчёт о правилах

Отчёт о правилах размещён в трёх окнах (рис. 9):

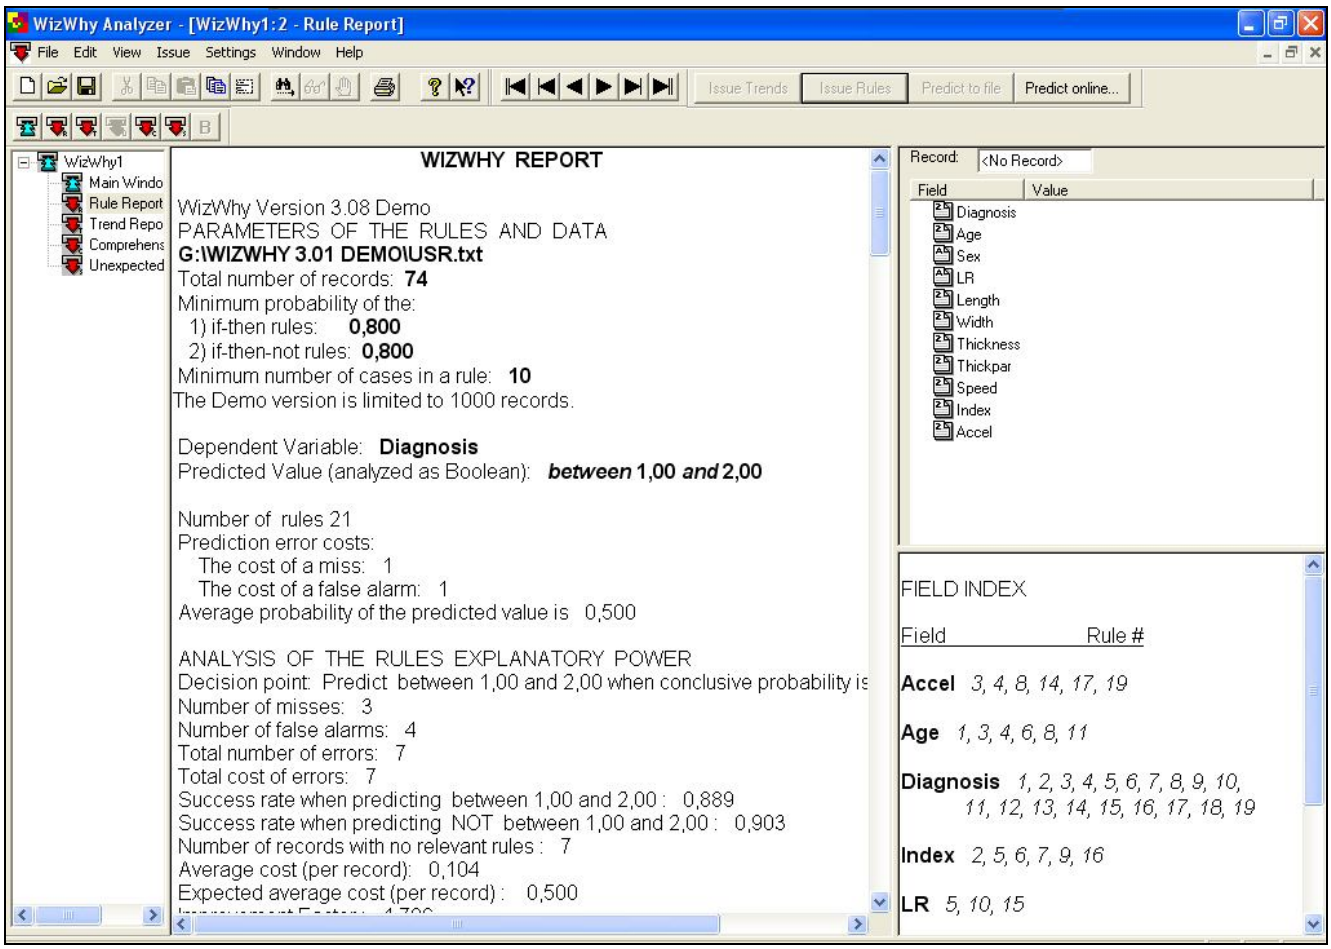

Рис. 9

- Левое окно – список правил (Rule List).
- Правое верхнее окно – содержание записи в деталях (Record Details Grid).
- Правое нижнее окно – индекс признака (Field Index).

7. Список правил

Список правил предваряется информацией о заданных параметрах поиска. Здесь на примере данных по ультразвуковой диагностике почек, как видим, говорится, что общее число обработанных записей (объектов) составляет 74, минимальная вероятность правил if-then и if-then-NOT равны по 0.8, минимальное количество объектов для правил – 10. Затем подтверждается, что правила находятся для переменной Diagnosis, конкретно для значения этой переменной, равного 2 (если в пункте 2 программа у вас «вылетала», то в строке Predicted Value будет указано: between 1,00 and 2,00). Также указывается, что стоимость ошибок в виде пропусков и ложных тревог составляет 1, а средняя вероятность (априорная вероятность) прогнозируемого значения переменной равна 0.5

Далее система выдаёт следующий блок общей информации об обнаруженных правилах:

ANALYSIS OF THE RULES EXPLANATORY POWER
Decision point: Predict between 1,00 and 2,00 when conclusive probability is more than **0,572**
Number of misses: 3
Number of false alarms: 4
Total number of errors: 7
Total cost of errors: 7
Success rate when predicting between 1,00 and 2,00 : 0,889
Success rate when predicting NOT between 1,00 and 2,00 : 0,903

Number of records with no relevant rules : 7
Average cost (per record): 0,104
Expected average cost (per record) : 0,500
Improvement Factor: 4,786

Из приведённого блока можно почерпнуть сведения о значениях некоторых служебных параметров - Decision point (точка решения), Average cost (средние потери (на запись)), Expected average cost (ожидаемые средние потери) и Improvement Factor (выигрыш), представляющий собой отношение ожидаемых средних потерь к реальным потерям на запись.

Точка решения – когда WizWhy формирует прогноз, то вычисляется вероятность того, что значение зависимой переменной в анализируемой записи равно «1» (допустим «1» – это спрогнозированное значение зависимой переменной). Эта вероятность называется итоговой (conclusive). Если значение итоговой вероятности больше значения точки решения, то прогнозируемое значении = 1, а если меньше, то не равно 1.

Средние потери на запись – общая сумма ошибок, поделённая на количество записей в исследуемом массиве данных.

Ожидаемые средние потери есть результат формирования прогноза только на основании частоты появления прогнозируемого значения, стоимости пропуска объекта, стоимости ложной тревоги. Другими словами – это ожидаемые средние потери при условии, что неизвестно ни одного правила. Например, пусть частота появления прогнозируемого значения = 15%, стоимость пропуска объекта = 2, а стоимость ложной тревоги = 1. В этом случае, если в анализируемых записях не найдено ни одного правила, то WizWhy формирует следующий прогноз: «прогнозируемое значение зависимой переменной не встречается ни в одной записи из исследуемого набора». В таком случае (для прогноза такого вида) средние потери на запись называются ожидаемыми средними потерями. Для данного примера они будут равны 0.3 (15% (или, другим словами, 0.15) умножить на 2 и умножить на 1 = 0.3).

Кроме того, в блоке содержатся сведения о прогнозирующей способности все совокупности обнаруженных правил – количество пропусков при прогнозировании (Number of misses), число ложных тревог (Number of false alarms), общее количество ошибок (Total number of errors), общие потери (Total cost of errors), вероятность успешного прогнозирования для класса 2 (Success rate when predicting 2), вероятность успешного прогнозирования альтернативного класса (Success rate when predicting NOT 2) и количество объектов, не охваченных выделенными правилами (Number of records with no relevant rules).

Список правил состоит из правил, упорядоченных по заданному критерию. В данных по ультразвуковой диагностике почек при установленных параметрах система WizWhy обнаружила 19 правил. Рассмотрим (для примера) правило № 5:

5) *If* **LR** *is* **R**
and **Speed** *is* **16,30 ... 41,50** (average = **25,44**)
and **Index** *is* **0,70 ... 0,80** (average = **0,72**)
Then
Diagnosis *is not* ***between* 1,00 *and* 2,00**
Rule's probability: **1,000**
The rule exists in **10** *records.*
Significance Level: Error probability < 0,001
Positive Examples (records' serial numbers):
3, 61, 63, 64, 65, 66, 67, 72, 73, 74

Это правило представляет собой конъюнкцию трёх элементарных высказываний. Первое - **LR** *is* **R** - говорит о том, что правило относится только к правой почке. Второе - **Speed** *is* **16,30 ... 41,50** – определяет диапазон значений для средней скорости кровотока, и третье - **Index** *is* **0,70 ... 0,80** – описывает интервал значений индекса резистентности. Высказывание **Diagnosis** *is not* ***between* 1,00 *and* 2,00** (или **Diagnosis** *is not* **2** – если у вас программа не «вылетала») означает, что правило характерно для объектов, не имеющих диагноз «множественные кисты».
Запись *Rule's probability:* **1,000** означает, что точность правила в данном случае равна 1. Следующая запись - *The rule exists in* **10** *records* – характеризует объём множества объектов, для которых справедливо рассматриваемое правило, а другая запись - *Significance Level: Error probability <* 0,001 – касается статистической оценки уровня значимости полученного правила (как видим, доверие к правилу превышает 90%). Последняя запись - *Positive Examples (records' serial numbers)* – означает «положительные» примеры, которые затем представлены как номера записей (объектов) в наборе данных.

Система WizWhy предоставляет возможность визуализации полученного правила. Для этого нужно щёлкнуть на правиле левой кнопкой мыши и затем с помощью правой кнопки вызвать контекстное меню, в котором выбрать диаграмму правила Rule Chart (рис. 10).

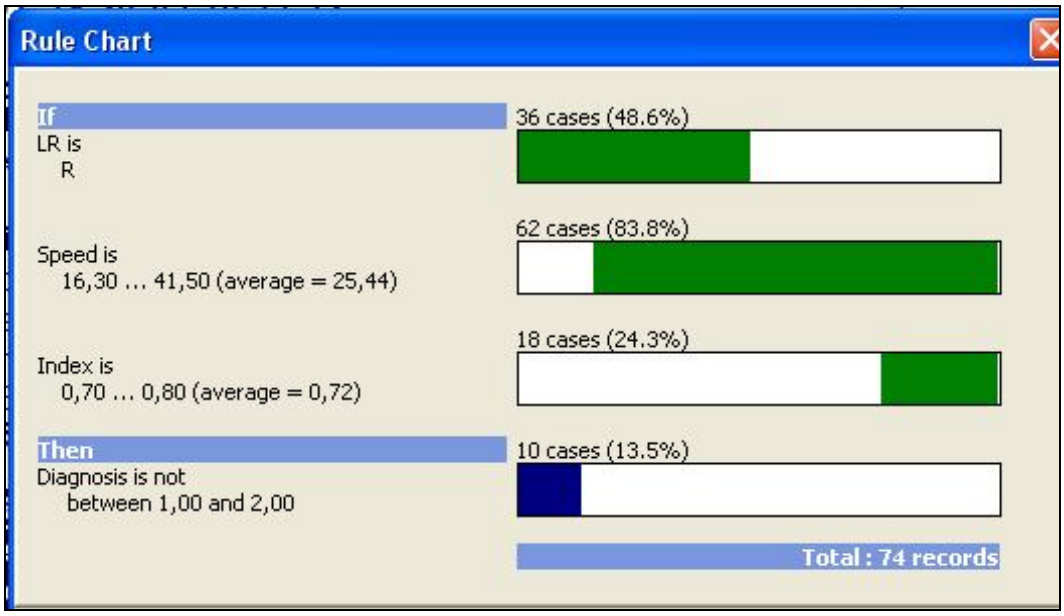

Рис.10. Диаграмма выделенного правила № 5

Эта диаграмма иллюстрирует отдельные компоненты правила и даёт графическое отображение совокупного взаимодействия переменных.

8. Содержание записи в деталях

Окно «Содержание записи в деталях» позволяет просмотреть значение признаков для каждого объекта. Для этого требуется ввести номер объекта в поле Record и нажать клавишу Enter. Пример для объекта № 25 приведён на рис. 11.

Другая возможность состоит в том, что если дважды щёлкнуть левой кнопкой мыши на номере объекта в списке правил, который там приведён в качестве положительного или отрицательного примера, соответствующие значения признаков отобразятся в рассматриваемом окне. При этом целевая переменная будет отмечена специальным значком красного цвета, а все остальные – значками зелёного цвета. Кроме того, на значках, расположенных сразу слева от названия признаков, указываются типы данных признаков.

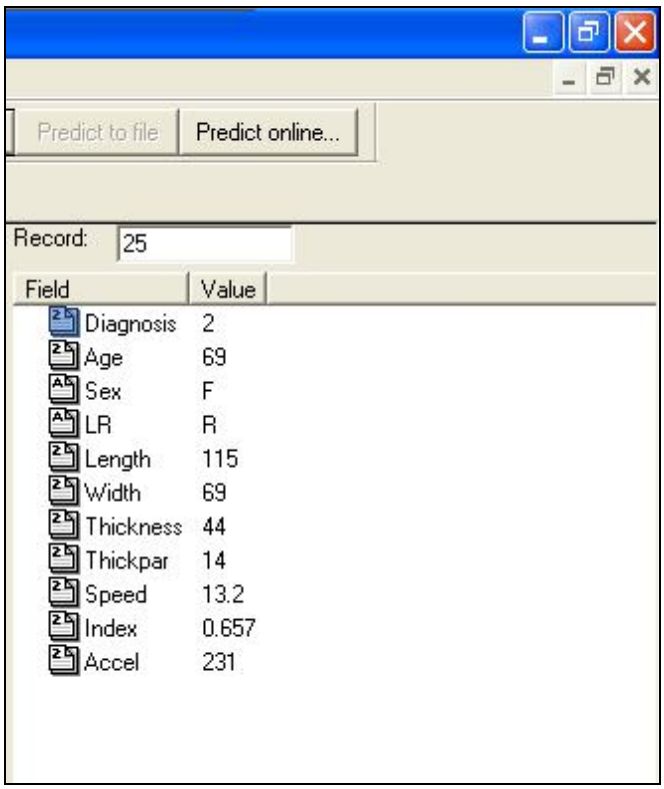

Рис. 11

9. Индекс признака

В окне «Индекс признака», расположенным в правом нижнем углу, отображаются порядковые номера правил, в которых появляются те или иные признаки (рис. 12).

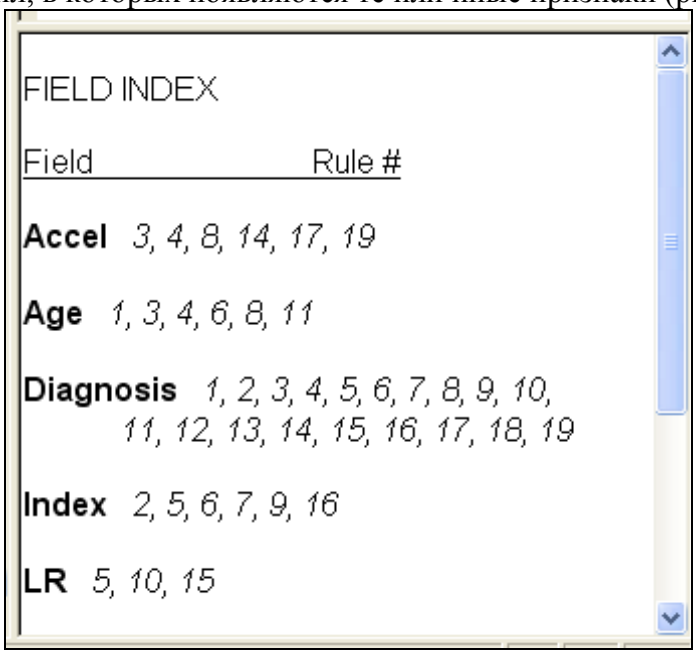

Рис. 12.

Можно просмотреть всё окно, используя прокрутку. Также в системе предусмотрена другая возможность – если в списке правил дважды щёлкнуть на каком-либо признаке в любом из правил, то этот признак будет автоматически выделен в окне «Индекс признака». По представляемой информации удобно выносить суждения о полезности признаков (о коэффициенте использования признаков) для классификации данных и прогнозирования. В свою очередь, если

дважды щёлкнуть в окне «Индекс признака» по любому номеру правила, то это правило моментально будет выделено в списке правил.

10. Распечатка и экспорт правил

Для распечатки правил или их экспорта в другой файл требуется нажать соответствующую кнопку печати на главном окне WizWhy – на экране появится специальное диалоговое окно Print Rules (рис. 13).

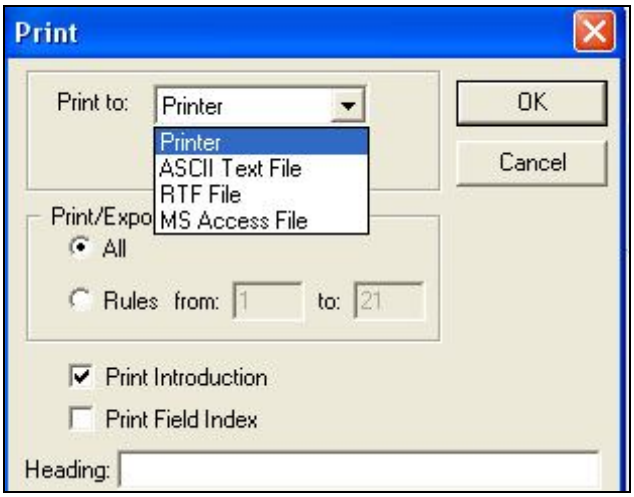

Рис. 13

В поле Print to указывается адрес, по которому направляется результирующая информация. В поле Print/Export range указывается диапазон порядковых номеров правил, которые должны быть распечатаны или экспортированы. В нижней части окна диалога проставляются по необходимости флажки для распечатки или экспорта введения к списку правил Print Introduction и содержимого окна «Индекс признака». Кроме того, в поле Heading моно ввести заголовок для результирующей информации.

11. Отчёт о трендах

Отчёт о трендах представляет результаты сегментации отдельных признаков. Окно данного отчёта разделено на три области (рис. 14).

В области, расположенной в левом верхнем углу, мы задаём анализируемый признак (Field to be analyzed). Здесь можно не только выбирать требуемый признак, но и сортировать признаки по какому-либо критерию (в алфавитном порядке, по номеру поля, по информативности).

Другие две области предназначены для отражения отношений между значениями признака и зависимой переменной. В верхней правой области окна отчёта приводятся статистические характеристики сегментов выделенного признака. В нижней области отчёта приводится графическая иллюстрация информативности каждого сегмента. На графике по горизонтальной оси располагаются сегменты, на которые выбранный признак автоматически разбивается системой WizWhy. По вертикальной оси откладывается отношение количества объектов класса if-then к общему количеству объектов, попадающих в сегмент. Таким образом, высота столбиков на графике отражает информативность сегментов. Если столбик выше синей горизонтальной черты, значит, в данный сегмент чаще попадают объекты класса if-then, а если ниже горизонтальной черты – класса if-then-NOT. В свою очередь, ширина столбиков пропорциональна количеству объектов, относящихся к данному сегменту.

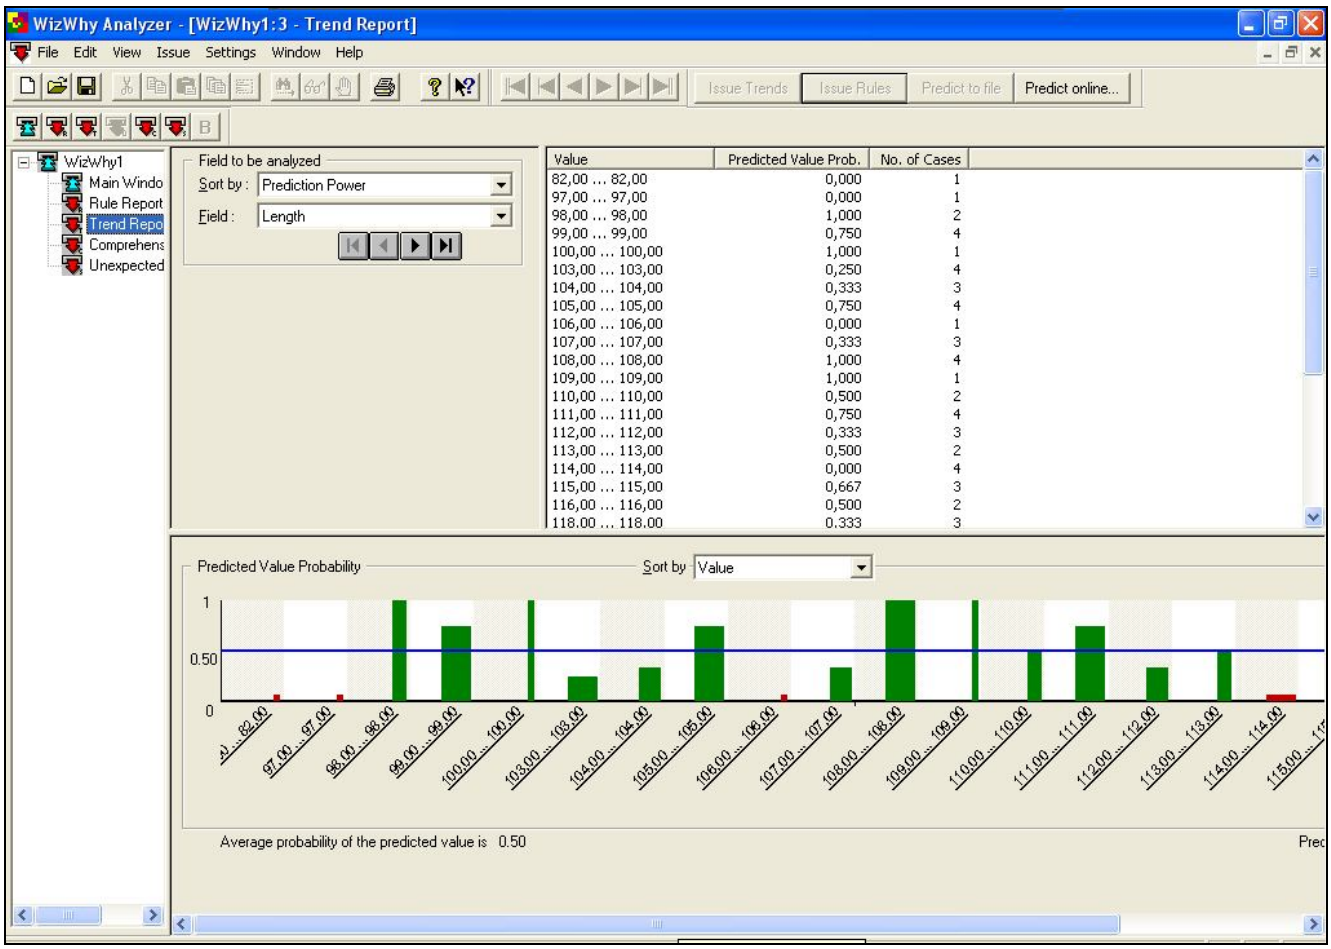

Рис. 14

12. Отчёт о неожиданных правилах

В системе WixWhy введено представление о так называемых неожиданных правилах (unexpected rules). Под неожиданными понимаются правила в виде конъюнкции двух и более простых высказываний, комбинация которых даёт точность и полноту прогноза выше, чем это можно было бы ожидать при независимости простых высказываний. Это представление, по-видимому, имеет цель дополнительно заинтриговать конечного пользователя возможностью открывать в данных нетривиальные закономерности.

В нашем случае система не обнаружила таких неожиданных правил. Однако можно попытаться это сделать, если мы изменим задание на поиск правил. Например, уменьшим минимальную вероятность if-then- и if-then-NOT-правил с 80 до 70% в окне Rule Parameters. Проделайте указанную операцию и нажмите кнопку Issue Rules – теперь система обнаружит в данных по ультразвуковой диагностике 38 правил, и среди них окажется 4 неожиданных, отчёт о которых выдаётся в специальном окне (рис. 15). Окно отчёта о неожиданных правилах разделено на три секции. В левой верхней секции отображается в стандартной форме найденное неожиданное правило. Правая верхняя секция содержит информацию об элементах, из которых составлено неожиданное правило. И наконец, нижняя секция предназначена для сортировки неожиданных правил и графического представления результатов.

Так, в нашем случае первое неожиданное правило, изображённое на рис. 15, расшифровывается следующим образом: если (пол женский) и (ширина почки в интервале от 61 до 75) и (ускорение кровотока от 148 до 275), то диагноз (множественные кисты). Данное правило вместе с рассчитанными характеристиками приведено ниже. Здесь по сравнению с ранее рассмотренными характеристиками выдаются две новые – уровень неожиданности (Level of Unlikelihood) и ожидавшаяся вероятность правила (Expected rule probability) Как видно, за счёт взаимо-

связи элементов правила точность целого правила составила 0,999 и оказалась значительно выше ожидавшейся (0,81).

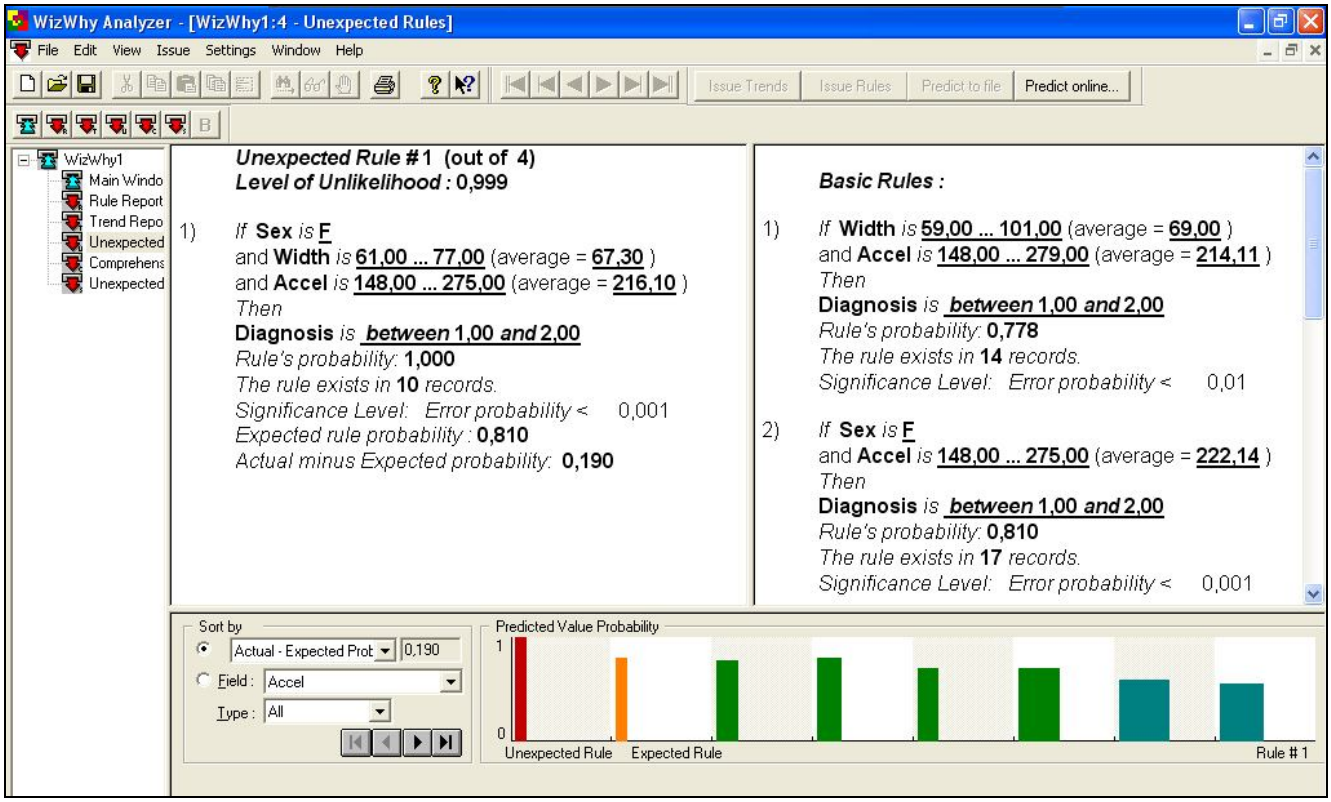

Рис. 15

***Unexpected Rule* # 1 (out of 4)**
***Level of Unlikelihood :* 0,999**

1) *If* **Sex** *is* **F**
and **Width** *is* **61,00 ... 77,00** (average = **67,30**)
and **Accel** *is* **148,00 ... 275,00** (average = **216,10**)
Then
Diagnosis *is* ***between* 1,00 *and* 2,00**
Rule's probability: **1,000**
The rule exists in **10** *records.*
Significance Level: Error probability < 0,001
Expected rule probability : **0,810**
Actual minus Expected probability: **0,190**

В правой верхней секции приводится статистический разбор компонентов, из которых состоит неожиданное правило. Оно состоит из двух частей (табл. 1)

Базисные правила (Basic Rules) представляют собой комбинации простых событий, входящих в неожиданное правило.

Базисные тренды (Basic Trends) – это статистический разбор сегментов анализируемых переменных, составляющих собственно логические события.

Как видим из таблицы, все компоненты неожиданного правила по отдельности имеют точность существенно ниже 1 – самое высокое значение точности наблюдается у базисного правила №2.

Нижняя секция отчёта о неожиданных правилах разделена на две части. В левой части располагаются элементы управления для сортировки этих правил. По умолчанию правила проранжированы по величине разности между реальной и ожидаемой точностями правил. Если ус-

тановить переключатель в поле Field и выбрать из списка какой-либо признак, то будут отображаться только те неожиданные правила, в которых встречается указанный признак. В свою очередь, в поле Type можно выбрать один из трёх типов фильтров правил: All (все правила), if-then-правила и if-then-NOT.

Табл.1

Basic Rules	Basic Trends
1) *If* **Width** *is* **59,00 ... 101,00** (average = **69,00**) and **Accel** *is* **148,00 ... 279,00** (average = **214,11**) *Then* **Diagnosis** *is* ***between* 1,00 *and* 2,00** *Rule's probability:* **0,778** *The rule exists in* **14** *records.* *Significance Level: Error probability <* 0,01 2) *If* **Sex** *is* **F** and **Accel** *is* **148,00 ... 275,00** (average = **222,14**) *Then* **Diagnosis** *is* ***between* 1,00 *and* 2,00** *Rule's probability:* **0,810** *The rule exists in* **17** *records.* *Significance Level: Error probability <* 0,001 3) *If* **Sex** *is* **F** and **Width** *is* **60,00 ... 85,00** (average = **68,29**) *Then* **Diagnosis** *is* ***between* 1,00 *and* 2,00** *Rule's probability:* **0,706** *The rule exists in* **12** *records.* *Significance Level: Error probability <* 0,1 4) *If* **Accel** *is* **148,00 ... 279,00** (average = **217,18**) *Then* **Diagnosis** *is* ***between* 1,00 *and* 2,00** *Rule's probability:* **0,706** *The rule exists in* **24** *records.* *Significance Level: Error probability <* 0,01	5) *If* **Sex** *is* **F** *Then* **Diagnosis** *is* **between 1,00 and 2,00** *Trend's probability :* **0,595** *The trend exists in* **25** *records.* 6) *If* **Width** *is* **59,00 ... 101,00** *Then* **Diagnosis** *is* **between 1,00 and 2,00** *Trend's probability :* **0,556** *The trend exists in* **20** *records.*

В правой части нижней секции отчёта о неожиданных правилах даётся графическое представление характеристик правил и их составляющих. Первый слева столбик относится к найденному неожиданному правилу – его высота равна точности, а ширина пропорциональна количеству покрываемых объектов. Следующий столбик отображает ожидавшиеся характери-

стики правила, а остальные столбики соответствуют описанным выше базисным правилам и трендам. Если щёлкнуть левой кнопкой мыши по какому-либо столбику, то система WizWhy автоматически изменит содержание верхних окон отчёта о неожиданных правилах. Можно также щёлкнуть правой кнопкой мыши – появляется контекстное меню, в котором можно выбрать иллюстрацию в виде диаграммы правила (Rule chart).

13. Прогнозирование на основе полученных правил

В системе WizWhy предусмотрены две возможности использования обнаруженных правил для предсказания значений целевого показателя на новом материале.

Первая возможность заключается в ручном вводе значений признаков и обработке нового одиночного объекта (записи). Она реализуется следующим образом.

Нажмите кнопку Predict online – на экран выдаётся диалоговое окно для ручного ввода значений признаков (рис. 16).

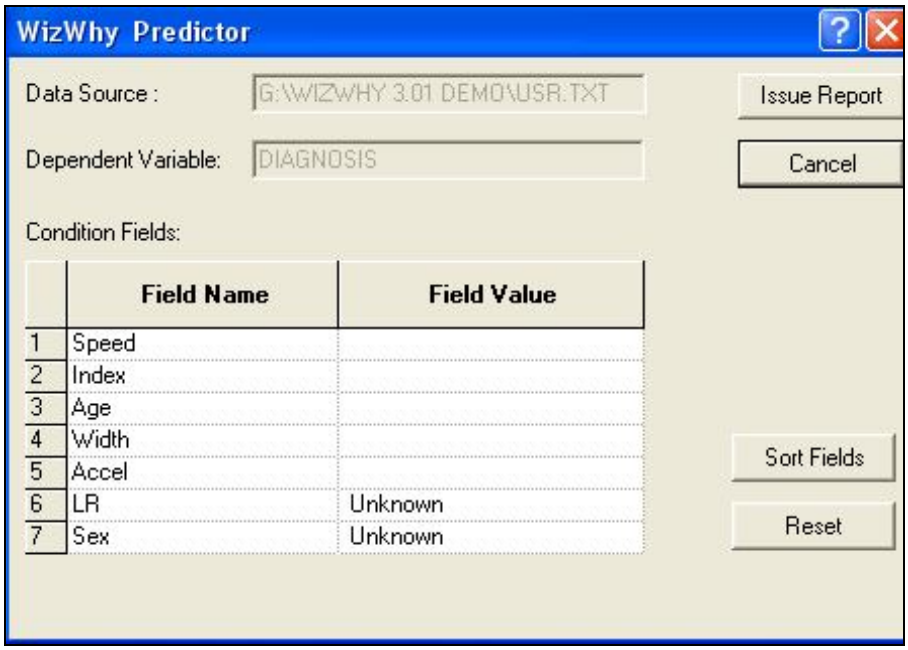

Рис. 16

После заполнения окошек предложенной таблицы (здесь возможны пропуски) нажмите кнопку Issue Report – система создаёт отчёт, в котором подробно описывает как конечный результат предсказания, так и характеристики каждого отдельного правила, использованных для получения прогноза. Пример отчёта представлен ниже:

WIZWHY PREDICTION REPORT

File Name: **G:\WIZWHY 3.01 DEMO\USR.txt**

Condition Fields:
Age = 50,00
Width = 60,00
Speed = 15,00
Index = 1,00
Accel = 1,00

Dependent Variable: **Diagnosis**
Subject for Prediction: **Diagnosis** is ***between* 1,00 *and* 2,00**

Prediction's significance level: Error probability = 0,000
Primary Prediction's probability: 0,500
Conclusive Prediction's probability: 0,884
Prediction: ***between* 1,00 *and* 2,00**

Relevant rules:

1) *If* **Age** *is* **46,00 ... 70,00** (average = **62,00**)
and **Speed** *is* **2,30 ... 15,40** (average = **13,17**)
Then
Diagnosis *is* ***between* 1,00 *and* 2,00**
Rule's probability: **0,909**
The rule exists in **10** *records.*
Significance Level: Error probability < 0,01

2) *If* **Width** *is* **54,00 ... 87,00** (average = **64,82**)
and **Speed** *is* **2,30 ... 15,40** (average = **13,28**)
Then
Diagnosis *is* ***between* 1,00 *and* 2,00**
Rule's probability: **0,909**
The rule exists in **10** *records.*
Significance Level: Error probability < 0,01

3) *If* **Speed** *is* **2,30 ... 15,40** (average = **13,28**)
Then
Diagnosis *is* ***between* 1,00 *and* 2,00**
Rule's probability: **0,833**
The rule exists in **10** *records.*
Significance Level: Error probability < 0,1

Как видим, в данном случае система выдала предсказание, что рассматриваемый объект относится к классу 2. Это решение система приняла на основании трёх правил.

Вторая возможность использования множества правил заключается в обработке сразу большого массива новой информации. Для этого перейдите к закладке Prediction Input в окне диалога для ввода данных и в ней укажите файл, в котором записана новая информация. Пусть это будет тот же самый файл с обучающей выборкой USR.txt. Затем требуется задать имя файла, в который будут записываться результаты прогнозирования. Данная операция осуществляется с помощью кнопки Print result to… И наконец, нажимается кнопка Predict to file – система производит необходимые расчёт и сообщает, что результаты успешно записаны в указанный файл.

Итогом выполнения первой части данной работы должны быть:

1. Прогноз, полученный при помощи опции Predict online (ручной ввод) для произвольной записи. Результаты скопируйте в файл: WizWhy_1_Фамилия.doc.
2. Прогноз, полученный при помощи опции Predict online (для большого массива файлов); используйте файл USR.txt.

ЧАСТЬ 2

В качестве источника данных выберите файл Stock (таблица Companies1) (в папке «WizWhy»). Зависимая переменная – «Industry» - может принимать следующие значения:

1. 036 - Software & Programming
2. 0727 - Regional Banks
3. 1018 - Computer Services
4. 0803 - Biotechnology & Drugs
5. 0909 - Business Services
6. 0730 - S&Ls/Savings Banks
7. 0812 - Medical Equipment & Supplies
8. 0915 - Communications Services
9. 1024 - Electronic Instruments & Controls
10. 0721 - Misc. Financial Services
11. 1003 - Communications Equipment
12. 0933 - Real Estate Operations
13. 1030 - Scientific & Technical Instruments
14. 0609 - Oil & Gas Operations
15. 0218 - Misc. Capital Goods
16. The others.

Выберите согласно вашему варианту из вышеприведённого списка значение зависимой переменной. Установите следующие значения параметров:

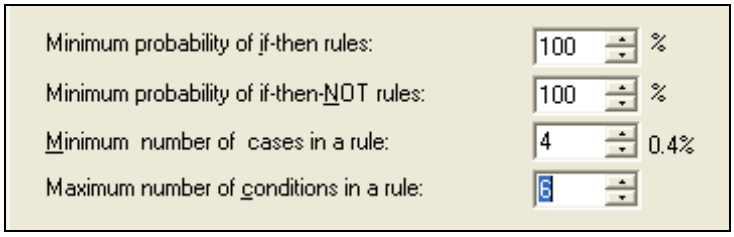

Выполните процедуру поиска правил. После этого, при помощи опции Predict online выполните прогнозирование на основе полученных правил (в качестве анализируемого набор данных выберите таблицу Companies2 из файла Stock).

Содержание отчёта (часть 2): Аналогично части 1.

Контрольные вопросы:

1. Назовите форматы файлов, с которыми может работать WizWhy.
2. Дайте понятие зависимой и независимой переменной. Приведите примеры.
3. Опишите процесс задания параметров поиска правил.
4. Поясните содержимое окна Error Costs.
5. Каково максимальное число элементарных логических событий, которое может обнаружить WizWhy в данных?
6. Поясните состав блока общей информации об обнаруженных правилах.
7. Поясните структуру правила, обнаруживаемого при помощи WizWhy.
8. Как функционирует опция Predict online?

Практическая работа №2. Разработка базы данных. Обнаружение правил при помощи системы WizWhy.

1. Разработка базы данных (в MS Access).

База данных должна содержать не менее 15 логических правил (уникальных записей). Подобные правила принято представлять в виде следующего условного суждения:

$$ЕСЛИ\ (условие)\ ТО\ (результат),$$

где $условие$ - набор объектов принадлежащих некоторому множеству, с которыми ассоциированы объекты, входящие в $результат$ правила. Пусть $условие = X$ и $результат = Y$, тогда правило можно представить в следующем виде:

$$если\ X\ то\ Y.$$

Условная часть правила может содержать до 6 элементарных логических событий. Каждое из правил должно повторяться в базе данных не менее 4 раз. Т.о., минимальное количество записей в базе данных:

Таблица 1

Кол-во элементарных логических событий в условной части правила	Кол-во типов правил	Кол-во повторов правил		
6	5	4		
3	5	4		
1	5	4	Всего (минимум):	60 правил

Все параметры (зависимая и независимые переменные) должны принимать только целочисленные значения. Если переменная текстовая (например, «Пол»), то используёте цифровую кодировку (например, 1 – «пол мужской», 0 – «пол женский»). Не используйте в качестве параметров правил Ф.И.О. и даты.

2. Обнаружение правил при помощи системы WizWhy.

При помощи опции Predict online (ручной ввод значений) выявите в базе данных сформированные правила.

3. Содержание отчёта

   1) Перечень созданных правил.
   2) Результаты работы Predict online (15 отчётов) в следующем виде:

WIZWHY PREDICTION REPORT

File Name: **G:\WIZWHY 3.01 DEMO\USR.txt**

Condition Fields:

Age = **50,00**
Width = **60,00**
Speed = **15,00**
Index = **1,00**
Accel = **1,00**

Dependent Variable: **Diagnosis**
Subject for Prediction: **Diagnosis** is ***between* 1,00 *and* 2,00**
Prediction's significance level: Error probability = 0,000
Primary Prediction's probability: 0,500
Conclusive Prediction's probability: 0,884
Prediction: ***between* 1,00 *and* 2,00**

Relevant rules:

1) *If* **Age** *is* **46,00 ... 70,00** (average = **62,00**)
and **Speed** *is* **2,30 ... 15,40** (average = **13,17**)
Then
Diagnosis *is* ***between* 1,00 *and* 2,00**
Rule's probability: **0,909**
The rule exists in **10** *records.*
Significance Level: Error probability < 0,01

2) *If* **Width** *is* **54,00 ... 87,00** (average = **64,82**)
and **Speed** *is* **2,30 ... 15,40** (average = **13,28**)
Then
Diagnosis *is* ***between* 1,00 *and* 2,00**
Rule's probability: **0,909**
The rule exists in **10** *records.*
Significance Level: Error probability < 0,01

3) *If* **Speed** *is* **2,30 ... 15,40** (average = **13,28**)
Then
Diagnosis *is* ***between* 1,00 *and* 2,00**
Rule's probability: **0,833**
The rule exists in **10** *records.*
Significance Level: Error probability < 0,1

3) Выводы по работе (должны содержать информацию о количестве и полноте обнаруженных правил)